

基於多模態特徵與堆疊架構之AI邊緣運算釣魚威脅偵測系統

A Phishing Threat Detection System for AI Edge Computing Based on Multimodal Features and Stacking Architecture

陳育毅指導教授、陳澤宇、廖丞惟、王昱殊
國立中興大學資訊管理學系

摘要

網路詐騙手法日益精進，傳統依賴靜態網址規則或黑名單的偵測技術，已難以應對駭客不斷更新的技術與心理戰術。過往研究雖嘗試導入雲端大型語言模型（LLM）進行語意分析，卻衍生出嚴重的資料隱私外洩風險與 API 連線延遲問題。為突破此技術瓶頸，提出一套基於本地小型語言模型與多模態堆疊集成學習的即時偵測系統。

系統核心技術包含：(1) **多模態特徵工程**：整合網址統計特徵（45 項）、DOM 結構特徵（16 項）與本地量化小型語言模型萃取之語意特徵（15 項），共建構 76 維高維度特徵空間；(2) **異質集成模型**：採用兩層式堆疊架構，於基礎層部署 XGBoost 基學習器，並透過邏輯回歸（Logistic Regression）元模型進行決策融合；(3) **本地化邊緣推論**：利用 CUDA 與 llama-cpp 框架實作可解釋 AI 機制，系統將底層特徵逆向解析為資安邏輯，並依此生成「風險診斷報告」。在確保隱私下提供即時風險評估與診斷報告。

實驗結果顯示，本系統展現優異的防禦效能，ROC AUC 達 0.9987。更關鍵的是，堆疊架構成功將單一模型的「決策猶豫區間」大幅壓縮至僅剩 0.06%，同時將「高自信區間」推升至 99.69%，展現出極致的決策穩定度。此外，透過 AI 生成之診斷報告增加模型可解釋性，使系統決策邏輯透明化。最終系統封裝為本地 Flask API 與支援 NDJSON 串流技術之 Chrome 擴充功能，實現

兼具隱私保護、低延遲與極致偵測效能的落地應用。

關鍵詞：釣魚網站偵測、多模態特徵、堆疊架構、邊緣運算、小型語言模型、語意診斷、可解釋 AI

Abstract

As cyber-attacks become increasingly sophisticated, traditional detection techniques relying on static URL rules or blacklists are difficult to counter hackers' constantly updating technical and psychological tactics. While previous research attempted to introduce cloud-based Large Language Models (LLMs) for semantic analysis, it led to serious data privacy leakage risks and API connection latency issues. To break through this technical bottleneck, this study proposes a real-time detection system based on a local Small Language Model and multi-modal stacked ensemble learning.

This research developed an "AI Edge Computing Phishing Threat Detection System based on Multi-modal Features and Stacked Architecture" to solve the pain points of privacy concerns in cloud detection and the "decision hesitation" of traditional models. The core contributions include: (1) **Multi-modal Feature Engineering**: Integrating URL statistics (45 items), DOM structure (16 items), and semantic features extracted by a local Qwen-8B (15 items) to construct a 76-dimensional feature space, filling the gap in "Social Engineering Intent

Recognition" of traditional methods. (2) Heterogeneous Stacked Ensemble Architecture: Utilizing XGBoost as the base layer and Logistic Regression as the meta-model for final decision integration. Experimental results confirm that after stacking, the "hesitation interval" significantly decreases, and the "high-confidence interval" is improved. (3) Localized Edge Inference: Utilizing the CUDA and llama-cpp frameworks to implement an Explainable AI mechanism. The system reverse-parses underlying features into cybersecurity logic and generates "Risk Diagnosis Reports" accordingly, providing real-time risk assessments and diagnosis reports while ensuring privacy.

Experimental results show that this system demonstrates superior defensive performance, with an ROC AUC of 0.9982. More importantly, the stacking architecture successfully compresses the decision "ambiguity interval" to a mere 0.06% while boosting the "high confidence interval" to 99.69%, exhibiting extreme decision stability. Furthermore, the AI-generated diagnosis reports increase model interpretability, making the system's decision logic transparent. Finally, the system is encapsulated as a local Flask API and a Chrome Extension supporting NDJSON streaming technology, realizing a practical application that features privacy protection, low latency, and ultimate detection performance.

Keywords: Phishing Detection, Multi-modal Features, Stacked Architecture, Edge Computing, Small Language Model, Semantic Diagnosis, Explainable AI

1. 緒論

1.1 研究背景與動機

隨著數位金融與電子商務的普及，網際網路已成為現代生活不可或缺的一部分，然而網路釣魚（Phishing）亦隨之演進並成為重大資安威脅。傳統的釣魚網站偵測技術多半依賴黑名單或基於網址字元特徵的靜態規則比對，此類方法存在顯著的滯後性，難以防禦駭客不斷變動網域與伺服器 IP 的「零時差」攻擊。此外，現今攻擊者不再僅依賴簡單的惡意網址，而是透過精密的社交工程話術、偽造知名品牌視覺以及動態跳轉等複合型技術建構偽造網頁，使得缺乏「深度語意理解」能力的傳統機器學習模型面臨嚴峻挑戰。

為填補傳統統計特徵與真實詐騙意圖之間的語意鴻溝，近年開始嘗試將大型語言模型匯入資安防禦領域以深度解析網頁文本情感。然而，多數方案高度依賴雲端 API（如 OpenAI），衍生出兩大致命痛點：

- (1) **資料隱私外洩風險**：將使用者的真實瀏覽紀錄、URL 或網頁原始碼傳送至第三方雲端伺服器，極易引發敏感個資外洩的問題。
- (2) **連線延遲與運算成本**：頻繁調用雲端 API 會產生昂貴的運算費用，且受限於網路延遲，難以在前端瀏覽器提供獨立且即時的「瀏覽即偵測」回饋。

基於上述痛點，本研究轉向邊緣運算思維，旨在本地端架設量化之小型語言模型，打造一套兼顧絕對隱私、低延遲與深度語意分析能力的防禦系統。

1.2 研究目的與方法

本研究主要目的在於建構一套整合本地小型語言模型與多模態堆疊集成學習之即時釣魚網站偵測系統。針對現有雲端模型所引發的隱私外洩與延遲問題，提出以下核心機制與設計：

在語意萃取層面，本研究導入經 4-bit 量化壓縮之開源小型語言模型（Qwen3-8B-Q4_K_S），利用 CUDA 加速與 llama-cpp 框架，於本地端獨立辨識網頁中之急迫感、威脅性與誘導登入等 15 項深層詐騙意圖，徹底阻斷數據上傳雲端之風險。為提升防禦架構之廣度，系統建構了包含 76 維特徵之多模態空間，針對 URL 網址（45 項）、HTML 結構（16 項）與 AI 語意（15 項）三大模態，分別運用 XGBoost 作為基底學習器，並配合 Optuna 自動化框架進行超參數最佳化。

在堆疊架構設計上，本研究並非採用傳統的隨機交叉驗證，而是實作嚴格的「分層抽樣與反向過濾隔離機制」，徹底排除基底模型與元模型訓練集重疊之網址以防範過度擬合。經由產生獨立預測機率後，將其作為全新特徵向量匯入 Logistic Regression 元模型進行決策融合。實驗數據顯示，系統之 ROC AUC 表現高達 0.9987，將決策「猶豫區間」大幅壓縮至 0.06%，達成極高的決策自信度。

為落實前端應用，本系統將 Stacking 集成模型封裝為本地 Flask API，採用 NDJSON 非同步串流技術優化互動體驗，並搭配專屬之 Chrome 瀏覽器擴充功能。系統最終能即時生成包含風險指數與自然語言判斷理由之「AI 風險診斷報告」，解決傳統 AI 黑盒子痛點，實現兼具高隱私、低延遲與高可解釋性之終端防護方案。

1.3 研究範圍與限制

為確保研究之聚焦程度與系統運作之穩定性，本研究針對技術實作與應用情境設定以下範圍與限制：

1.3.1 硬體效能與部署環境限制

考量資安隱私之保護，本系統採用完全本地化部署，使用者設備須具備支持 CUDA 加速之 NVIDIA GPU。整體推論速度將受限於終端設備之運算能力。

1.3.2 推論延遲與長文本處理壓力

受限於邊緣端之硬體算力，系統整體推論運作時長約需 60 至 110 秒，主要瓶頸在於語言模型分析網頁文本之推論時間。此外，當目標網頁內容過於龐大時，文字特徵萃取之耗時將顯著增加，且可能超出 SLM 的上下文窗口限制。

1.3.3 樣本時效性與概念飄移風險

本研究之模型訓練樣本主要仰賴公開資料集與現有網址。面對駭客快速演進的動態釣魚技術與新型規避手法，模型在長期運作下可能面臨特徵退化與「概念飄移」之風險，未來需仰賴自動化更新機制以維持防禦效能。

2. 文獻探討

本章針對本研究主題進行脈絡化重整與分析，旨在說明本研究所依據之理論基礎，並探討傳統技術與現代邊緣運算模型在釣魚偵測領域的演進機制。

2.1 傳統釣魚網站偵測技術

早期針對釣魚網站的防禦機制，多半仰賴「黑名

單」技術。此類方法透過比對已知惡意網址的特徵庫來阻擋連線。雖然其具備極低的誤報率，卻受限於資料庫更新的滯後性，完全無法防禦尚未被舉報的零時差攻擊。

隨著機器學習技術的普及，相關研究重心逐漸由單一判斷轉向深層的特徵工程。回顧過往文獻，特徵萃取的方法大致可為以下兩大方向：

- (1) **網址詞彙特徵**：研究者常利用自然語言處理技術，這類方法著重於擷取網址字串中的物理屬性，包括字元長度、異常符號（如 @、-）的出現頻率，以及網域層級深度等。
- (2) **網頁結構特徵**：為了彌補網址分析的不足，後續研究開始深入解析 HTML DOM 樹結構。透過計算外部資源連結比例、統計隱藏標籤數量或分析表單的提交行為，從網頁內容的物理建構層面尋找詐騙跡象。

然而，駭客的技術也與時俱進。近年來，攻擊者大量使用 URL 混淆、短網址跳轉，甚至將惡意表單偽裝在正常的 HTML 結構中。傳統機器學習模型僅能捕捉「物理與統計層面」的異常，缺乏對網頁文本「語意與詐騙意圖」的深層理解，導致在面對精心偽裝、甚至使用合法網域託管的高階釣魚網站時，偵測準確率面臨嚴峻考驗。

2.2 小型語言模型於資訊安全之應用與演進

為彌補傳統模型缺乏語意理解的缺陷，近年開始大量探討大型語言模型的應用潛力。LLMs 能夠精準辨識網頁文本中如「急迫感」、「帳號停權威脅」或「品牌偽冒」等社交工程意圖。然而，直接將雲端 LLMs 應用於終端防禦系統，面臨著兩大難以克服的實務挑戰：

- (1) **隱私與合規性災難**：將使用者的瀏覽資料、URL 甚至網頁原始碼上傳至第三方伺服器進行推論，極易引發嚴重的資料外洩疑慮。
- (2) **高延遲與成本**：雲端 API 往返的網路延遲，無法滿足瀏覽器防護軟體所需的即時性，且頻繁調用雲端 API 會產生昂貴的運算費用。

為解決此痛點，本研究採用「邊緣運算」思維與「小型語言模型」。受惠於先進的模型量化技術，使用其他學者以量化壓縮之開源小型語言模型（Qwen3-8B-Q4_K_S）。這使得在一般終端消費級

硬體上，進行「本地執行」的深度語意解析成為現實。導入本地 SLM 不僅從根本上消除了資料外流的隱私風險，更確保了偵測系統的低延遲優勢。

2.3 集成學習架構與堆疊法

在機器學習的防禦應用中，單一演算法往往存在其演算法偏誤與效能瓶頸。為突破此限制，「集成學習」成為提升模型強健性的關鍵技術。常見的集成策略如 Bagging 與 Boosting，多半是基於「同質性」的弱學習器進行組合。相較之下，堆疊法則強調透過整合「異質」的專家視角來提升決策精準度。在本研究中，此「異質性」並非源於演算法的不同，而是來自於處理不同資料模式的專屬特徵空間。

標準的 Stacking 架構通常分為兩個層次：

- (1) 第一層 (Base Level / Level-0)：同時訓練多個專精於特定領域之異質專家模型。本研究針對 76 維的多模態特徵空間，採用 XGBoost 演算法作為基底學習器，並分別訓練三個獨立的模型：負責解析 URL 維度 (45 項特徵)、HTML 結構維度 (16 項特徵) 以及 AI 語意維度 (15 項特徵)。
- (2) 第二層 (Meta Level / Level-1)：將第一層各專家模型輸出之「預測機率值」整合為全新的特徵向量，再匯入元模型 (邏輯迴歸) 進行最終的決策融合。

Stacking 能夠有效整合不同模型的預測視角。為避免資料洩漏導致模型過度擬合，本研究實作了嚴格的分層抽樣與反向過濾隔離機制，確保基底模型與元模型的訓練集在網址層級完全互斥。特別是在面對釣魚網站這類具備多模態資料 (URL、HTML 結構、文本語意) 的複雜情境時，此 Stacking 架構能最大化各模態專屬 XGBoost 模型的防禦優勢，顯著提升整體的 ROC AUC 並將決策猶豫區間降至最低，建構出具備高度容錯能力的縱深防禦網路。

3. 研究方法

第三章將探討釣魚網站偵測系統的架構與實作方法，內容涵蓋系統的資料流、多模態特徵工程、資料集合併時之語意衝突排解方案，以及基於機

率融合之多模態堆疊集成學習架構設計。

3.1 系統總體架構概觀

關於本系統架構之詳細運作機制，其核心設計旨在提供完全本地化且具備高隱私與低延遲特性之即時防護，整體架構主要區分為前端攔截與本地後端處理兩大核心部分。

系統之運作流程始於前端之即時攔截機制，當使用者造訪未知網頁時，Chrome 擴充功能將即時擷取當前網頁之網址與 HTML 原始碼，隨後透過本地端通訊將資料發送至部署於使用者本機之 Flask API，確保數據傳輸過程完全不涉及雲端上傳，從而強化個資隱私之保障。

在資料進入後端處理階段後，系統將同步啟動三路特徵萃取管線，內容涵蓋網址靜態規則分析、HTML 結構解析，以及結合系統提示詞引導本地量化小型語言模型進行深層萃取之語意特徵，總計建構出包含 76 維度之多模態特徵空間。具體而言，網址維度涵蓋 45 項統計特徵，HTML 結構維度包含 16 項物理特徵，而 AI 語意維度則萃取包含急迫感、威脅性與誘導登入等 15 項深層意圖特徵。萃取完成之特徵隨即匯入第一層 (Level-0) 專家模型，包含針對網址、結構與 AI 語意優化之 XGBoost，由各專家模型獨立輸出判定為釣魚網站之預測機率值。最終，系統進入第二層 (Level-1) 元模型融合階段，將上述三個機率值作為全新特徵向量匯入邏輯斯迴歸元模型進行最終決策。為優化互動體驗與可解釋性，通訊過程採用 NDJSON 串流響應格式，能於解析過程中即時回傳掃描進度，並最終生成由 SLM 產出之自然語言診斷報告，達成一個閉環且具備高度解釋性之資安防護體系。

3.2 多模態特徵工程

本研究之多模態特徵工程旨在透過並行之萃取管線，從網址詞彙、網頁結構以及基於小型語言模型之深層語意等三大維度，全面擷取釣魚網站之惡意指標，總計建構出包含 76 維度之多模態特徵空間，為後續之集成學習模型提供具備高辨識力之特徵矩陣。(詳細特徵定義請參見文件手冊-系統計畫書之 8.2)。

3.2.1 URL 詞彙與結構特徵萃取

關於網址詞彙特徵之萃取，URL 往往作為辨識釣魚網站之首要防線，本系統根據預定義之 45 項統計邏輯計算萃取網址特徵。所擷取之離散與統計型物理特徵除涵蓋網址總字元長度、主機名稱長度與網域層級深度等結構性指標外，亦針對點號、連字號、@ 符號與底線等異常符號之出現頻率進行精確統計。此外，系統具備偵測 IP 位址嵌入、Punycode 編碼、頂級域名是否出現在路徑或子域名中，以及計算數字佔網址比例等特徵之能力，藉此初步過濾利用 URL 混淆或常見短網址服務進行跳轉之惡意連結。

3.2.2 HTML 結構與 DOM 樹特徵萃取

在 HTML 結構特徵萃取方面，系統深度解析程序並萃取共計 16 項關鍵指標。由於釣魚網站為追求視覺呈現之逼真度，常於底層原始碼中留有不合理之建構特徵，系統會計算網頁中超連結總數、內部與外部超連結比例、以及外部資源引用指向異常伺服器之比例。同時，系統針對內容中是否存在常見釣魚提示詞、網站提及品牌與域名是否一致、是否使用外部域名之 Favicon，以及表單提交路徑是否為空值或指向黑名單網域進行嚴格檢查，並偵測 meta 與 JavaScript 之轉向行為，從物理建構層面尋找詐騙跡象。

3.2.3 基於本地 SLM 之深層語意特徵萃取

為突破傳統特徵工程無法理解「詐騙意圖」之技術瓶頸，本系統創新導入本地量化開源模型進行深層語意萃取，主要採用經 4-bit 量化壓縮之 Qwen3-8B-Q4_K_S 模型，藉由 CUDA 加速於邊緣端執行。其執行流程始於文本預處理階段，透過對網頁 HTML 進行去標籤化處理以提取核心文本內容，隨後藉由提示詞工程將目標文本匯入小型語言模型，引導模型根據指定格式回傳包含預定義之 15 項文本特徵的回覆。內容涵蓋檢查文本是否營造急迫感、包含威脅語句、異常索取密碼或信用卡等敏感資訊、以及提供不切實際之獎勵。此外，系統亦評估文本是否存在語法錯誤、識別試圖冒充之品牌名稱、檢查版權年份合理性，並由模型給出頁面內容一致性評分與最終釣魚風險評分，將傳統難以量化的心理學社交工程意圖，成功轉換為數值化之 AI 語意特徵矩陣。

3.3 資料蒐集與預處理機制

為確保模型訓練資料的品質與泛化能力，本研究整合了兩大異質釣魚網站資料集：其一為 Kaggle 平台之公開網頁釣魚偵測資料庫；其二則為源自 NIST Phish Scale 之高質量釣魚網站樣本。面對龐大且動態變化的網頁樣本，本系統開發了一套具備高容錯性與非同步處理能力的自動化採集與標註流水線。

3.3.1 雙引擎網頁採集與動態渲染處理

在網頁結構與文本的採集上，本系統實作了一套基於非同步架構的雙引擎採集框架：

- (1) **動態渲染與轉址容錯**：為應對釣魚網站常見的進階迴避技術，系統結合了 aiohttp 靜態快取與 Playwright 動態渲染技術。在執行爬蟲時，系統會監聽特定的網路錯誤，並實作轉址容錯等待機制，確保能獲取跳轉後真實的惡意終端頁面與完整的 DOM 結構。
- (2) **視覺化文本採集與併發控制**：在獲取文本時，系統模擬人類閱讀視角，精準擷取網頁的純淨可見文本。為避免大規模採集導致記憶體溢出或網路阻塞，系統利用 `asyncio.Semaphore` 將最高併發數限制於 20，並具備 90 秒強制超時保護與資源阻斷技術（如阻擋多媒體載入），以最大化採集效能。

3.3.2 邊緣端 SLM 語意標註流水線

針對傳統特徵工程難以量化之「詐騙語意」，本研究建構了自動化的本地端語言模型標註流水線：

- (1) **結構化輸出與啟發式過濾**：系統於本地端載入量化之 Qwen-8B 模型，並透過 Pydantic Schema 強制規範模型必須針對 15 項心理特徵進行 JSON 格式化輸出。此外，為確保訓練集標記品質，系統實作了專家啟發式過濾邏輯，自動偵測並捨棄包含「404」或「頁面不存在」等關鍵字之無效失效網頁樣本。

- (2) **狀態驅動之斷點續傳機制**：面對數以萬計的樣本標註任務，系統實作了自動化重試與斷點續傳機制。由 Dataset_Manager 監控每筆資料的分析狀態，若遭遇推論失敗或程式中斷，系統能自動於下次啟動時接續未完成之任務，大幅提升大型資料集處理之穩定度。

3.3.3 多模態特徵對齊與防洩漏隔離機制

在完成網址、結構與語意三路特徵的平行萃取後，由於動態網頁爬蟲與本地語言模型推論在實務上可能遭遇連線逾時、防爬蟲阻擋或網頁失效，導致各模態成功採集的樣本數量與資料集合不盡相同。為建構高品質的 Stacking 訓練集並最大化基模型的資料利用率，本研究設計了「先取交集，後反向排除」的兩階段資料處理機制：

- (1) **嚴格交集與 Meta-Set 建立**：系統首先透過字串處理與去重機制確保網址索引的唯一性，並採用「嚴格交集」策略，僅提取在 URL、HTML 與 AI 語意三路特徵皆成功獲取的樣本，形成完整的交集資料集。接著，從此交集資料庫中以分層抽樣切出 50% 的資料，作為專供元模型 (Level-1) 訓練與最終驗證使用的專屬資料集 (Meta_Set)
- (2) **反向過濾與異質基模型訓練集生成**：為確保第一層基礎模型 (Level-0) 能獲得大量的訓練樣本，系統並非僅使用交集資料集的剩餘部分；而是回到 URL、HTML 與 AI 各自獨立的「原始資料庫」中，利用反向過濾運算 (如 Pandas 的 ~isin())，從中徹底排除所有已劃入 Meta_Set 的重疊網址。

此一資料切割機制不僅完美解決了各模態特徵因爬蟲失敗導致的「樣本不對齊」實務痛點，更確保了基礎層與元模型的訓練集在網址層級上達成絕對的資料隔離，從根本上防範了資料洩漏所引

發的過度擬合風險。

3.3.4 多模態特徵預處理與標籤編碼機制

在完成特徵萃取與資料集對齊後，為確保三路異質特徵能順利匯入機器學習模型，系統必須進行最終的特徵預處理與型態轉換。特別是針對基於本地端 SLM 生成之「AI 語意特徵」，其原始輸出多為布林值與字串型態，無法直接用於數值運算，因此系統針對不同特徵模態設計了專屬的預處理管線：

- (1) **語意特徵之標籤編碼**：針對 SLM 輸出的 15 項語意特徵，系統實作了自動化的標籤轉換機制。首先，將「是否營造急迫感 (creates_urgency)」、「是否包含威脅語句 (uses_threats)」等 14 項布林值欄位，強制轉換為 0 與 1 之整數型態。其次，針對識別試圖冒充品牌之 impersonated_brand 字串特徵，系統不採用高維度的獨熱編碼，而是依據其是否存在具體品牌名稱，將其二值化為「有冒用品牌 (1)」或「無明顯冒用 (0)」的數學特徵。
- (2) **樹狀模型之特徵對齊策略**：在完成標籤編碼與缺失值檢核後，考量本研究在基礎層 (Level-0) 的演算法評估中，最終全面選用 XGBoost 作為預測引擎，由於樹狀集成模型對於特徵的尺度不具敏感性，系統在最終匯入前刻意排除了全局標準化處理。此舉不僅減少了不必要的運算開銷，更保留了各維度特徵在決策樹節點分裂時的原始分佈特性，確保堆疊架構能獲取最真實的特徵訊號。

3.4 邊緣端語言模型建置與提示詞工程

本研究的核心創新在於將雲端語言模型遷移至邊緣端執行。為確保量化模型在有限算力下仍能精準理解社交工程語意，並維持系統診斷報告的生成品質，本系統設計了專屬的模型參數配置與雙階段提示詞工程。

3.4.1 本地化模型推論環境與參數配置

為達成「數據不離地」之隱私保護，本系統選用開源之 Qwen3-8B-Q4_K_S GGUF 4-bit 量化模型，並透過 llama-cpp-python 結合 CUDA 進行硬體加速。在推論參數設定上，為應對釣魚網站長篇距的網頁文本，系統將上下文窗口 (n_ctx) 擴展至 15,000 tokens，並設定 n_gpu_layers =30 將神經網路層最大化卸載至 GPU 運算。此外，為確保模型回覆的穩定性與低幻覺，特徵萃取階段之溫度參數限制於 0.4。

3.4.2 雙階段提示詞工程策略

針對釣魚偵測流程，系統實作了兩套獨立的提示詞管線，分別負責「數學特徵轉化」與「自然語言診斷報告生成」：

- (1) **第一階段-語意特徵結構化萃取:**在此階段，系統賦予語言模型「資深資安分析師」之角色定位，嚴格規範模型僅能依據輸入之純文本進行客觀推論，禁止過度衍伸。提示詞內明確定義了 15 項心理學與語意特徵（如：急迫感、威脅性、敏感資訊索取等）之判斷標準。最關鍵的是，系統在提示詞中強制啟用了 JSON 結構化輸出，並利用 PhishingSchema 規範回傳格式，成功將非結構化的網頁文本，穩定轉化為後續 XGBoost 樹狀模型可讀取的 15 維數值特徵向量。（完整系統提示詞定義請參見附錄 A）
- (2) **第二階段-可解釋性診斷報告生成:**在 Stacking 堆疊模型產出最終的「風險機率」後，系統啟動第二階段的提示詞管線。此階段將模型定位為「冷酷的資安系統 API」，強制禁止輸出「好的」、「首先」等擬人化對話贅字。系統會動態注入三個變數至提示詞中：Stacking 預測之風險機率、由系統底層特徵逆向解析出之理由清單，以及動態語氣指示。模型會根據風險機率的高低（如：<30% 為安心客觀、>70% 為強烈警告），融合特徵證據，生成約 100 字具備高度「可解釋性」的繁體中文最終評估報告，有效解決傳統 AI 黑盒子的使用者體驗痛點。（完整報告生成提示詞與語氣規則請參見附錄 B）。

3.4.3 知識驅動之可解釋性理由清單生成機

制

本系統 XAI 診斷報告的精準度，不僅仰賴語言模型的生成能力，更取決於輸入之特徵證據。為橋接「數學特徵向量」與「自然語言提示詞」之間的語意斷層，本研究實作了知識驅動的理由轉換邏輯。系統會攔截多模態特徵工程階段所觸發的惡意指標（如：ip 為 True、has_js_redirect 為 True、creates_urgency 為 True），並根據預先定義之專家資安規則，將其轉換為具體的文字理由（例如：「【網域異常】網址直接使用 IP 位址」、「【結構異常】網頁原始碼藏有自動跳轉指令」）。此理由清單將與 Stacking 模型之預測機率結合，共同作為邊緣端 SLM 的上下文輸入，確保 AI 最終生成的報告不會產生幻覺，具備絕對的邏輯一致性與證據追溯力（完整之理由清單映射規則請參見文件手冊-系統計畫書10.2及10.4）。

3.5 多模態堆疊集成架構與訓練機制

本系統之決策核心採用兩層式堆疊集成架構。有別於傳統將所有特徵混合訓練單一模型之作法，本研究透過分離網址、HTML 結構與 AI 語意三路特徵，建構專精於各領域之基礎層 (Level-0) 模型，再透過元模型 (Level-1) 進行決策融合，以達到最佳之防禦效能。

3.5.1 基礎層 (Level-0) 演算法選型與最佳化

在基礎層的建置上，系統需要分別處理 URL (45 維)、HTML (16 維) 與 AI 文本 (15 維) 三種異質空間之特徵。為決定最佳基模型，本研究針對各模態獨立進行了演算法對比實驗，評估 XGBoost、Fast SVM 與 MLP (多層感知器) 之表現。

實驗結果顯示，在面對非線性且具備多樣離散與連續數值的特徵時，樹狀集成演算法 XGBoost 在三路模態的 ROC AUC 與 F1-Score 指標上均顯著優於其他模型。因此，系統最終決策在三路預測路徑統一採用 XGBoost 作為核心預測引擎。在模型訓練階段，系統導入了 Optuna 自動化框架進行超參數調優，以 5-Fold 分層交叉驗證之 ROC AUC 平均值作為最佳化指標，針對 n_estimators

、max_depth 與 learning_rate 等關鍵參數進行廣泛搜索，確保各模態模型能在其專屬特徵空間中達到效能極值。

3.5.2 元模型 (Level-1) 決策融合與風險輸出

第一層基模型訓練完成後，系統會收集三路 XGBoost 模型產出之獨立預測機率($P(url, html, ai)$)。這三個介於 0 到 1 之間的機率值將被合併為一組全新的三維特徵向量，並饋送至第二層的邏輯迴歸元模型中進行學習。

選用邏輯迴歸作為元模型之原因，在於其具備極佳的線性解釋性與抗過擬合能力，能客觀地學習到「在不同情境下，應賦予哪一個模態較高的信任權重」。透過此一決策融合機制，系統不僅能有效吸收多模態特徵，更將傳統單一模型的「猶豫區間」大幅壓縮，輸出最終具備極高自信度的釣魚風險機率。當最終風險機率產出後，系統將連同高貢獻度之特徵一併交由邊緣端 SLM，生成最終的自然語言診斷報告。

3.5.3 類別不平衡處理與模型權重優化

在真實世界的資安防禦情境中，正常網站與釣魚網站的樣本分佈往往存在顯著的類別不平衡。為避免模型因學習樣本不均，而過度傾向預測多數類別導致漏報率上升，本系統在兩層式堆疊架構的訓練管線中，均導入了嚴格的權重平衡機制：

- (1) **基礎層 (Level-0) 的動態權重調整**：在訓練 URL、HTML 與 AI 語意三路 XGBoost 基模型時，系統會自動計算訓練集中的正負樣本比例，並將計算出之 ratio 動態賦值給 XGBoost 演算法的 scale_pos_weight 參數。此機制能在損失函數 (Loss Function) 計算階段，自動加重少數類別錯誤預測的懲罰，迫使模型更專注於捕捉稀有的惡意特徵。
- (2) **元模型 (Level-1) 的類別平衡器**：在接收基礎層產生的三維預測機率後，考量到決策融合層仍可能受到特徵分佈不均的影響，第二層的邏輯迴歸元模型特別啟用了 class_weight='balanced' 參數。此設定確保了元模型在進行最終決策邊界的劃分時，能維持絕對的客觀性，進一步提升系

統面對未知零時差攻擊時的強健性與泛化能力。

3.6 邊緣端系統防護架構與非同步串流實作

本系統之最終目的在於實務落地。為兼顧高隱私防護與優異的使用者體驗，本研究結合了前端瀏覽器擴充功能與本地輕量化伺服器，建構出完整的終端防禦管線。

3.6.1 終端應用：Chrome 瀏覽器擴充功能與隱私傳輸

為提供直覺且便捷的防護體驗，本研究以前端技術開發專屬之 Chrome 瀏覽器擴充功能，並嚴格遵循 Google 最新的 Manifest V3 架構規範，確保在安全性與權限控管上符合現代化標準。在即時資料擷取機制方面，當使用者觸發偵測需求時，系統透過 popup.js 呼叫 Chrome Extension API 獲取當前活躍分頁之完整 URL，並動態注入內容腳本即時提取網頁之 HTML 結構與純文本內容。隨後，多模態原始資料將封裝並發送至部署於使用者本機端之伺服器。此傳輸過程完全於本地環路中進行，不經過任何外部網際網路或第三方雲端服務，從根本上消除了數據攔截或瀏覽紀錄外洩之資安風險。

3.6.2 本地伺服器架設與 NDJSON 串流管線

系統之核心推論引擎部署於本地端之 Flask 微服務框架中。為最小化推論延遲並優化系統反應速度，伺服器於啟動時即執行模型反序列化與資源預載流程，預先將訓練完成之 Stacking 堆疊模型權重（包含三路 XGBoost 基模型與邏輯迴歸元模型）以及經 4-bit 量化之 Qwen3-8B 語言模型載入記憶體，以規避每次請求時重複加載模型所產生之運算開銷。

在通訊架構上，本系統創新引入 NDJSON 串流技術。由於本地小型語言模型在進行語意萃取時需耗費較長之推論時間，傳統 JSON 回傳方式極易引發前端連線超時與使用者焦慮。故系統改採非同步串流管線，當伺服器接收請求後，會依序觸發 URL 特徵向量化、HTML 解析與 SLM 語意分析。系統將各階段的分析進度（如：「正在解析

網頁文本...」、「進行最終分析...」)與初步判定結果,透過 NDJSON 分段傳輸至前端。此機制不僅解決了邊緣端運算之效能瓶頸,更讓使用者能即時掌握偵測進度,大幅提升人機互動體驗。

3.6.3 後端推論引擎之物件導向封裝與資料管線

為確保邊緣端推論系統之高內聚力與低耦合度,並應付複雜之多模態資料流,本系統後端捨棄傳統的腳本式撰寫,全面採用嚴謹之物件導向程式設計進行模組化封裝。系統核心資料管線由以下四大類別協同運作,確保前端請求至最終報告產出之資料傳遞具備高度安全性與穩定性:

- (1) **API 控制層 (PhishingDetectorAPI):**
作為系統之主入口與控制器,負責管理 Flask Web Server 的生命週期。當接收到前端擴充功能傳入之網址與原始網頁結構後,本類別會啟動 `generate_progress()` 方法,利用非同步生成器排程特徵萃取任務,並將各階段進度透過 NDJSON 串流即時回饋至前端。
- (2) **多模態特徵萃取層 (FeatureExtractor):**
: 專責處理原始數據之轉換。此類別內建了 `get_URL_Feature()` 與 `get_HTMLStructure_Feature()` 等方法,根據預定義之資料字典萃取物理特徵;同時負責調度底層之語言模型以取得 AI 語意特徵,並透過 `get_reason_list()` 方法將觸發之惡意指標轉換為可解釋性之理由清單。
- (3) **機器學習預測層 (PhishingDetectorModel):**
負責封裝所有經 Optuna 最佳化訓練之 AI 權重(包含三路 XGBoost 基模型與邏輯迴歸元模型)。此類別內之 `predict()` 方法會將前端傳入之三路特徵向量進行防呆檢查、標籤編碼與預處理,隨後將其依序匯入 Level-0 與 Level-1 模型,完成 Stacking 架構之決策融合並產出最終機率。
- (4) **邊緣語言模型封裝層 (QwenLLM 與 PhishingSchema):**
為管理本地端 Qwen-8B 量化模型所設計。透過封裝

llama-cpp 之硬體加速配置(如 `n_gpu_layers=30`、`n_ctx=15000`),提升 GPU 效能。同時結合 PhishingSchema 強制規範 JSON 輸出格式,確保非結構化文本能穩定轉換為特徵陣列與最終之 AI 診斷語句。

4. 實驗設計與結果分析

本章節旨在透過量化的模型效能指標與質化的實務診斷報告,驗證本研究提出之「多模態堆疊集成架構」在釣魚網站偵測上的防禦有效性與系統穩定性。實驗將分為基礎層演算法選型、堆疊模型效能驗證,以及實務邊緣運算情境下之可解釋性診斷與效能測試。

4.1 實驗環境與評估指標設定

為確保邊緣運算推論的客觀性與本地化隱私保護,本實驗之軟硬體環境配置如下:運算核心採用 NVIDIA GeForce RTX 3060 Laptop GPU 以支援 4-bit 量化之 SLM 推論,並搭配 CUDA 12.1 與 Python 3.13 進行加速。

在測試資料集的切割上,本實驗採用完全未參與基礎層與元模型訓練的 Meta_Set 獨立 20% 子集(共 10,918 筆異質樣本)進行最終效能驗證。在評估指標方面,除了常規的 ROC AUC、準確率與 F1-Score 外,本研究為驗證「決策穩定性」,特別導入以下進階機率分佈指標:

- (1) K-S 統計量:衡量模型對正負樣本的機率分化距離,數值愈大代表排序能力愈佳。
- (2) 猶豫區間比例:預測風險機率落於 0.4 至 0.6 之間的模糊地帶樣本比例,數值愈低代表模型決策越果斷。
- (3) 高自信區間比例:風險機率大於 0.9 或小於 0.1 的極端樣本比例,數值愈高代表系統之自動攔截依據越具說服力。

4.2 單一模態基礎層 (Level-0) 模型效能與選型

為決定最佳之多模態基底引擎,本研究針對 URL (192,611 筆)、HTML 結構 (71,005 筆)與 AI 語意文本 (81,036 筆)三路獨立資料集,分別執行 XGBoost、Fast SVM 與 MLP 的超參數最佳化

與效能對比實驗。實驗結果如圖4.2(使用指標為 ROC AUC)。

實驗結果顯示，XGBoost 在三路模態的 ROC AUC 表現均為最優：URL 模態達 0.9959、HTML 模態達 0.8785、AI 文本模態達 0.8285。相較於 SVM 與 MLP，XGBoost 在處理具備高度非線性與離散特徵的釣魚網站數據時展現出卓越的適應力，因此本系統在 Level-0 全面採用 XGBoost 作為基礎層核心預測引擎。

1. URL (192611筆資料) :
- a. XGBoost: 0.9959
- b. Fast SVM: 0.9573
- c. MLP: 0.9947
2. HTML (71005筆資料) :
- a. XGBoost: 0.8785
- b. Fast SVM: 0.8159
- c. MLP: 0.8671
3. AI Text (81036筆資料):
- a. XGBoost: 0.8285
- b. Fast SVM: 0.7515
- c. MLP: 0.7776

圖4.2

4.3 多模態堆疊模型之效能驗證與決策極化

本節旨在驗證 Level-1 元模型整合「網址、結構、語意」三路特徵後，對整體防禦縱深與決策穩定度的具體貢獻。

4.3.1 常規效能評估

從獨立測試集的結果可見，整合後的堆疊模型（Meta Model）繳出了 ROC AUC 0.9987、Accuracy 0.9945、F1-Score 0.9969 的優異表現。儘管相較於單純只看 URL 特徵的模型（ROC AUC 0.9981），堆疊模型的精準率與召回率僅有極微幅的波動，但堆疊架構有效吸收了 HTML 與 AI 特徵作為輔助核對機制，大幅提升了面對「合法短網址」或「高信譽網域遭駭」等針對性逃逸攻擊時的抗規避能力。

4.3.2 決策極化效應與猶豫區間消除

從Meta_Set中切割出20%做為測試集，來觀察不同模型對於此測試集的表現，結果如圖4.3.2.1及4.3.2.2。

本研究最大的實驗發現，在於堆疊架構能極大幅

度地消除機率預測的「灰色地帶」：

- (1) 單一模型的猶豫缺陷：若僅依賴 HTML 或 AI 文本模型，其正常與釣魚類別的機率分佈波峰呈現扁平且高度重疊。單一 HTML 與 AI 模型的「猶豫區間比例」分別高達 6.92% 與 14.63%，實務上難以作為系統自動攔截的絕對依據。
- (2) 堆疊模型的決策極化效應：當導入 Stacking 架構後，元模型將雙峰極端地推向兩側（極度靠近 0 與 1）。實驗數據證明，堆疊模型將「猶豫區間比例」進一步壓縮至僅剩 0.06%，同時將「高自信區間比例」推升至 99.69%。此一極端分化的機率分佈證明了異質模型間具備強大的特徵互補性，使系統在給出預測時具備絕對的決策把握。

此外，堆疊模型的 K-S Score (98.98) 與 Brier Score (0.0050) 雖較單一 URL 模型出現微幅退化，但這並非效能低落，而是模型被推向高自信區間後，對少數邊緣誤判案例給予更重懲罰（Brier Score 特性），以及融合多模態訊號對純網址排序產生擾動的必然權衡。總體而言，犧牲極微小的排序完美度換取防禦縱深與 0.06% 的極低猶豫率，在實務上極具價值。

	Model	ROCAUC	Accuracy	Precision	Recall	F1-Score
0	URL Model	0.9981	0.9947	0.9985	0.9954	0.9970
1	HTML Model	0.8384	0.8710	0.9427	0.9088	0.9255
2	AI Text Model	0.7747	0.8333	0.9339	0.8726	0.9022
3	Meta Model	0.9987	0.9945	0.9989	0.9949	0.9969

圖4.3.2.1

	Model	K-S Score (↑)	Brier Score (↓)	Ambiguity Ratio (%) (↓)	High Confidence Ratio (%) (↑)
0	URL Model	99.00	0.0043	0.17%	98.13%
1	HTML Model	53.09	0.1100	6.92%	18.39%
2	AI Text Model	43.09	0.1415	14.63%	4.77%
3	Meta (Stacked) Model	98.98	0.0050	0.06%	99.69%

圖4.3.2.2

4.4 實務情境診斷與邊緣運算效能分析

考量終端防護系統的實用性，本研究進一步對系統進行了實際網頁的 XAI 診斷測試與邊緣端資源壓力分析。

4.4.1 可解釋性 AI 診斷測試

考量終端防護系統的實用性與使用者信任度，本研究針對真實網頁樣本進行了 XAI 診斷測試。系統不僅能輸出量化的風險機率，更能將觸發的特徵轉換為自然語言報告。為確保測試環境之安全性，本研究調用資料庫中已知標籤的原始數據進行模擬推論注入。

以下為系統面對不同風險情境時之實際診斷產出對比：

案例類型	風險指數(%)	AI 診斷理由(節錄)
正常網站 A	0.51	評估為相對安全。雖存在網頁標題不符等疑點，但綜合分析顯示其風險極低，未偵測到惡意程式或主動攻擊行為。
正常網站 B	4.62	未發現顯著安全風險。雖存在自動跳轉指令與缺乏聯絡資訊等少量可疑特徵，但網頁結構完整且無惡意載入行為，符合一般標準。
釣魚網站 A	99.46	具有極高釣魚風險！網頁標題空白且與網域名稱無關聯，缺乏品牌一致性，同時未提供實體地址與聯絡電話。
釣魚網站 B	99.50	具有極高風險！原始碼藏匿 login/verify 等釣魚關鍵字，且無實體地址與聯絡資訊，顯示為高風險釣魚網站。

從上述結果可見，系統能精準捕捉不同程度的風險並給出對應解釋。在「正常網站 B (4.62%)」的案例中，系統展現了優異的容錯與綜合判斷能力，並未因單一異常特徵（如缺乏聯絡資訊）而產生過度預警。

為具體展示終端使用者的互動體驗，圖 4.4.4.1 與圖 4.4.4.2 分別擷取了系統面對極端低風險（0.51%）與極端高風險（99.46%）時的實際前端視覺介面



圖 4.4.4.1

原因：該網站具有極高釣魚風險！網頁標題空白且與網域名稱無關聯，缺乏品牌一致性，同時未提供實體地址與聯絡電話等必要資訊，顯示來源可疑。請立即停止訪問並切勿輸入任何個人資料，以免遭受詐騙或資料洩漏。

圖 4.4.4.2

4.4.2 邊緣端硬體負載與推論延遲分析

受限於「數據不離地」的嚴格隱私要求與終端硬體限制，測試顯示，自使用者觸發掃描至最終 XAI 報告產出，總耗時約落在 60 至 110 秒之間

。效能瓶頸主要集中於語言模型對長文本的語意解析階段（約佔八成時間）。此外，在 RTX 3060 設備上運行 4-bit 量化模型時，偶爾會因 VRAM 滿載而降速至 CPU 運算。儘管存在推論延遲，但本研究已成功驗證本地端 SLM 用於資安語意診斷之技術可行性，未來可透過模型蒸餾或更高效之推論引擎進一步優化響應時間。

5. 結論與未來展望

本研究透過多模態特徵整合與邊緣運算技術，成功建構了一套兼具高準確度、絕對隱私與高可解釋性之釣魚網站偵測系統（ModaGuard）。本章將總結研究成果、探討實務應用之限制，並提出未來之研究方向。

5.1 研究總結

本研究成功實作基於異質堆疊集成架構之資安偵測引擎，並達成以下三項核心學術與實務貢獻：

- (1) 多模態特徵融合與決策極化效應：本研究整合網址統計、DOM 結構與本地端 SLM 萃取之文本語意，建構出 76 維的多模態特徵空間。實驗證實，堆疊模型成功吸收了多模態特徵之互補性，將決策「猶豫區

間」大幅壓縮至 0.06%，顯著提升了自動化防禦系統的決策穩定度與抗規避能力。

- (2) **可解釋型 AI 的落地應用**：本研究創新地將語言模型與傳統機器學習預測引擎結合。透過知識驅動的專家規則與數據驅動的 AI 推論，系統能將傳統的「黑盒子」機率，轉化為具備嚴謹資安邏輯的繁體中文診斷報告，大幅提升終端使用者對資安預警之信任感。
- (3) **本地化邊緣防護 (Edge AI)**：系統利用 CUDA 加速與 4-bit GGUF 量化技術，成功實現大型語言模型 (Qwen-8B) 的全本地端推論。在確保「數據不離地」的原則下，徹底解決了依賴雲端 LLM 所衍生的敏感個資外洩風險與高昂 API 成本。

5.2 系統限制與實務挑戰

儘管本系統在測試中展現出優異的防禦效能，但在推動實務部署時，面臨以下硬體與技術限制：

- (1) **硬體資源門檻與推論延遲**：考量絕對的隱私保護，本地運行之 SLM 需佔用約 5.8GB 的 VRAM，對於缺乏獨立顯卡之終端設備而言具備較高之運行門檻。此外，系統整體推論時長約需 60 至 110 秒，且面對長篇幅網頁時，特徵萃取耗時將顯著增加並可能超出 SLM 之上下文窗口限制，對於極度要求即時攔截之防護情境仍有優化空間。
- (2) **樣本時效性與模型特徵限制**：面對快速演進的動態釣魚技術，依賴靜態訓練集之模型在長期運作下可能面臨「概念飄移」之特徵退化風險。同時，實驗顯示 HTML 與 AI 文本之基礎層模型效能較純網址模型稍弱，若遭遇極端混淆之網頁結構，可能對整體排序能力產生微幅擾動；且當前依據特徵映射之「理由清單」，其細膩度與多元性亦有待進一步擴充。

5.3 未來研究展望

針對上述限制，未來的研究與系統迭代可朝以下方向進行改良：

- (1) **模型蒸餾與混合式動態分析架構**：未來可研究將 Qwen-8B 蒸餾為專精於「網頁意

圖分析」的極小型模型以降低硬體負載；並導入「兩階段過濾機制」，對於網址特徵極度異常之明顯威脅立即攔截，僅針對疑似社交工程之高欺騙性網頁啟動 SLM 深度語意分析，以完美平衡推論效能與防護深度。

- (2) **對抗性攻擊防禦與安全沙盒機制**：針對目前 LLM 容易遭受之「提示詞注入」攻擊，未來應研發專屬之攔截器，防止駭客透過隱藏網頁內容誤導模型決策。此外，可探索結合 Docker 技術實現前端安全隔離，提供使用者進入可疑網頁前的「虛擬代瀏覽」回饋，達成零風險預防。
- (3) **多維特徵擴充與自動化情資更新**：未來計畫擴大 HTML 與文本特徵維度以提升辨識力，並將核心推論引擎移植至行動端瀏覽器等跨平台生態系；同時建構自動化爬蟲對接即時資安威脅情報流，透過線上學習定期更新模型權重，以確保系統具備對抗零時差攻擊之長效防禦力。

參考文獻

- Xie, L., Zhang, H., Yang, H., Hu, Z., Cheng, X., & Zhang, L. (n.d.). A Review of Phishing Detection Research.
- Dawkins, S., & Jacobs, J. (n.d.). Phishing for User Context: Understanding the NIST Phish Scale. National Institute of Standards and Technology (NIST).
- 黃彥蓉 (n.d.). Web page Phishing Detection.
- 林子南 (n.d.). 淺談釣魚攻擊之釣魚網站.
- ILTM 研究團隊 (n.d.). 網路釣魚特徵.
- Anti-Phishing Working Group (APWG). (n.d.). Shashwatwork. (n.d.). Web Page Phishing Detection Dataset. Kaggle. Retrieved from <https://www.kaggle.com/datasets/shashwatwork/web-page-phishing-detection-dataset/data>
- Qwen Team. (n.d.). Qwen3-8B-GGUF. Hugging Face. Retrieved from <https://huggingface.co/unsloth/Qwen3-8B-GGUF>